

Cải tiến mô hình Nhận dạng giọng nói tự động đa người nói (MASR) cho tiếng Việt dựa trên TS-RoPE và Hyper-SD

Nguyễn Thăng Long, Đỗ Công Huy, Nguyễn Đức Lương, Trần Trung Hiếu, Hồ Viết Hoàng
Trường Đại học FPT, Hà Nội, Việt Nam

Abstract

Nhận dạng giọng nói tự động đa người nói (MASR) nhằm mục đích dự đoán “ai nói khi nào và nói gì” từ giọng nói của nhiều người nói, một công nghệ quan trọng cho việc hiểu hội thoại đa bên. Tuy nhiên, hầu hết các phương pháp hiện có đều tách rời mô hình thời gian và mô hình người nói khi giải quyết vấn đề “khi nào” và “ai”: một số phương pháp chèn tín hiệu người nói trước khi mã hóa (ví dụ: che giấu người nói), điều này có thể gây mất thông tin không thể phục hồi; những phương pháp khác kết hợp danh tính bằng cách trộn hậu nghiệm người nói sau khi mã hóa, điều này có thể làm lẫn lộn nội dung âm thanh với danh tính người nói. Sự tách biệt này dễ bị lỗi trong điều kiện luân phiên lượt nói nhanh và giọng nói chồng chéo, thường dẫn đến hiệu suất suy giảm. Để giải quyết những hạn chế này, chúng tôi đề xuất một khung thống nhất mô hình hóa đồng thời danh tính người nói và thời gian trong bộ mã hóa giọng nói. Cụ thể, chúng tôi thiết kế TS-RoPE, một mã hóa vị trí quay theo thời gian và người nói: tọa độ thời gian được lấy từ chỉ số khung, trong khi tọa độ người nói được lấy từ hoạt động của người nói và tín hiệu tạm dừng. Bằng cách áp dụng các góc xoay cụ thể theo vùng, mô hình nắm bắt rõ ràng tính liên tục của lời nói, sự chuyển đổi lượt nói và động lực trạng thái, cho phép cơ chế chú ý đồng thời xử lý cả “khi nào” và “ai”. Hơn nữa, để ước tính hoạt động của người nói ở cấp độ khung hình, chúng tôi phát triển Hyper-SD, phương pháp này phân loại người nói trong không gian hyperbol để tăng cường khả năng phân tách giữa các lớp và tinh chỉnh ước tính hoạt động của người nói. Các thí nghiệm mở rộng chứng minh hiệu quả của phương pháp đề xuất.

1. INTRODUCTION

MASR không chỉ nhận dạng “nói gì” mà còn phải biết “ai nói” và “nói lúc nào” trong một đoạn thoại có nhiều người nói xen kẽ, thậm chí chồng lấn. Do đó chúng tôi mong muốn cải tiến mô hình bằng cách đưa TS-RoPE vào encoder để tích hợp tự nhiên thông tin thời gian và hoạt động người nói và Hyper-SD – mô hình diarization trong không gian hyperbolic, dùng “feature-prototype distance” để ước lượng hoạt động speaker theo frame. Đồng thời chúng tôi sẽ sử dụng một bộ dữ liệu giọng nói vùng miền để có thể cải thiện chất lượng nhận dạng giọng nói của mô hình.

2. RELATED WORKS

2.1. Multi-speaker ASR và pipeline SD + ASR

MASR nhằm dự đoán đồng thời “ai nói khi nào và nói gì” trong các đoạn hội thoại nhiều người, thường được xây dựng bằng cách kết hợp riêng rẽ giữa diarization và ASR [1]. Các hệ thống truyền thống thường dùng một mô hình speaker diarization để ước lượng ranh giới và danh tính người nói theo thời gian, sau đó áp dụng mô hình ASR đơn-speaker và căn chỉnh hai luồng kết quả bằng timestamp. Cách tiếp cận dạng pipeline này dễ bị suy giảm hiệu năng trong bối cảnh hội thoại có nhiều lượt chuyển lời nhanh và speech chồng lấn, do sai số ở timestamp hoặc diarization sẽ lan thẳng sang bước gán speaker cho transcript.

2.2. Whisper, WhisperX và các hệ MASR dựa trên Whisper

Whisper là mô hình ASR đa ngôn ngữ đã được ứng dụng rộng rãi [1]. Tuy nhiên, nhiều phân tích chỉ ra rằng chất lượng của Whisper giảm đáng kể trên các ngôn ngữ ít dữ liệu, trong đó có tiếng Việt [2]. WhisperX mở rộng Whisper bằng cách thêm VAD, alignment mức từ và pipeline diarization bên ngoài. Dù vậy, WhisperX vẫn giữ cấu trúc “ASR + diarization tách rời” và phụ thuộc mạnh vào chất lượng mô hình diarization bên ngoài; các báo cáo thực nghiệm cho thấy diarization có thể không ổn định, đặc biệt trên audio dài hoặc ngôn ngữ ngoài tiếng Anh [3].

2.3. Mô hình MASR tích hợp TS-RoPE và Hyper-SD

Gần đây, một số công trình đề xuất mô hình tích hợp luân “who” và “when” vào cùng encoder thay vì chỉ ghép kết quả sau. Mô hình giới thiệu TS-RoPE, một cơ chế rotary position encoding nhận thức đồng thời thời gian và trạng thái người nói, bằng cách phân tách kênh Query/Key thành các dưới-không-gian thời gian và speaker, từ đó giúp self-attention học trực tiếp cấu trúc “ai nói khi nào”. Bên cạnh đó, Hyper-SD được sử dụng để tăng khả năng tách biệt giữa các speaker và tạo ra ước lượng hoạt động speaker theo frame ổn định hơn làm đầu vào cho TS-RoPE [2].

2.4. ASR tiếng Việt và khoảng trống nghiên cứu

Đối với tiếng Việt, hiệu năng của Whisper/WhisperX vẫn còn hạn chế, đặc biệt với sự đa dạng vùng miền. Một số mô hình chuyên biệt như PhoWhisper đã được đề xuất nhằm cải thiện chất lượng nhận dạng bằng cách huấn luyện lại trên dữ liệu tiếng Việt lớn hơn, nhưng đa số tập trung vào ASR đơn-speaker, chưa giải quyết bài toán

MASR có gắn nhãn speaker [3].

2.5. Vị trí đóng góp

Tóm lại, các hệ thống dựa trên Whisper/WhisperX hiện chủ yếu xử lý ASR và diarization dưới dạng các module tách biệt, trong khi các phương pháp MASR tích hợp như TellWhisper mới chủ yếu được đánh giá trên ngôn ngữ tài nguyên cao và chưa được điều chỉnh cho tiếng Việt. Trong công trình này, chúng tôi hướng tới việc kết hợp ý tưởng TS-RoPE và Hyper-SD vào một kiến trúc MASR dựa trên Whisper, đồng thời fine-tune trên bộ dữ liệu hội thoại đa vùng miền tiếng Việt, nhằm cải thiện đồng thời chất lượng nhận dạng nội dung và gắn nhãn người nói cho tiếng Việt.




Figure 1: Mô hình Hyper-SD [2]

3. DATA AND METRICS

3.1. Datasets

Để giải quyết bài toán nhận dạng giọng nói đa người nói và tối ưu hóa cho tiếng Việt đa vùng miền, nghiên cứu này sử dụng hai bộ dữ liệu chính: AMI Meeting Corpus cho bài toán diarization chuẩn và ViMD đã được xử lý overlap cho bài toán nhận dạng tiếng Việt đa phương ngữ.

3.1.1. Bộ dữ liệu AMI (AMI Meeting Corpus)

Công bố năm 2006 bởi đại học Edinburgh, gồm 100 giờ ghi âm từ 79 cuộc họp tiếng Anh, với sự tham gia của 4 người nói trong mỗi cuộc họp [4][5]. Dữ liệu được ghi âm tại tần số lấy mẫu 16 kHz. Chúng tôi sử dụng AMI vì đây là bộ dữ liệu có chú thích thủ công chi tiết về định danh người nói (speaker identity) và các vùng chồng lấn giọng nói (overlapping speech). Dữ liệu bao gồm cả người bản xứ và không bản xứ, tái tạo các điều kiện âm học phức tạp thực tế.

3.1.2. ViMD

Đối với tác vụ nhận dạng tiếng Việt, chúng tôi sử dụng ViMD (Vietnamese Multi-Dialect Dataset) để đảm bảo tính bền vững của mô hình trước sự đa dạng của phương ngữ tiếng Việt. Bộ dữ liệu bao gồm 102.56 giờ ghi âm, được thu thập từ các chương trình phỏng vấn trên truyền hình với sự tham gia của 12,955 người nói đến từ 63 tỉnh thành Việt Nam. Dữ liệu được chia thành ba tập huấn luyện (train), kiểm thử (dev) và đánh giá (test).

Đối với bộ dữ liệu này chúng tôi đặc biệt augment dữ liệu để tạo overlap. Chúng tôi áp dụng chiến lược trộn dữ liệu nhân tạo (synthetic mixing) trên tập huấn luyện với tỷ lệ 50% dữ liệu sạch (single-speaker) và 50% dữ liệu chồng lấn (overlapped speech). Với các mẫu chồng lấn, một mẫu âm thanh phụ (x_{interf}) được trộn vào mẫu chính (x_{target}) theo công thức:

$$x_{mixed} = 0.5 \cdot x_{target} + 0.5 \cdot x_{interf} \quad (1)$$

Thời điểm bắt đầu chồng lấn được chọn ngẫu nhiên từ giây thứ 0.3 đến khi kết thúc mẫu chính. Nhãn văn bản (transcript) được cấu trúc nối tiếp theo định dạng token người nói, ví dụ: <|spk1|> text_A <|spk2|> text_B, hỗ trợ mô hình học đồng thời nội dung và định danh người nói.

3.2. Metrics

Chất lượng nhận dạng được đo lường thông qua hai chỉ số chính: Tỷ lệ lỗi từ (Word Error Rate - WER) và Tỷ lệ lỗi ký tự (Character Error Rate - CER). Trong đó, WER được xác định bằng tổng số các thao tác chỉnh sửa tối thiểu bao gồm: Thay thế (S), Xóa (D) và Chèn (I) cần thiết để biến đổi chuỗi dự đoán khớp với chuỗi tham chiếu (N), theo công thức:

$$WER = \frac{S + D + I}{N} \times 100\% \quad (2)$$

Chỉ số Tỷ lệ lỗi phân đoạn (Diarization Error Rate - DER) được sử dụng làm thước đo cốt lõi để đánh giá khả năng xác định danh tính người nói theo thời gian. DER được tính bằng tổng thời lượng của ba loại sai số thành phần chia cho tổng thời gian tiếng nói thực tế (T_{total}):

$$DER = \frac{E_{miss} + E_{fa} + E_{conf}}{T_{total}} \quad (3)$$

Trong đó:

- **Lỗi bỏ sót (Miss Error - E_{miss}):** Khoảng thời gian có người nói nhưng hệ thống không phát hiện được.
- **Lỗi báo giả (False Alarm - E_{fa}):** Khoảng thời gian hệ thống báo có tiếng nói nhưng thực tế là khoảng lặng hoặc nhiễu môi trường.
- **Lỗi nhầm lẫn (Speaker Confusion - E_{conf}):** Khoảng thời gian hệ thống xác định đúng sự hiện diện của tiếng nói nhưng gán sai nhãn định danh người nói.

Để đánh giá chi tiết độ chính xác của các biên thời gian (boundaries), hệ thống sử dụng các chỉ số Precision, Recall và F1-score:

$$Precision = \frac{TP}{TP + FP}; \quad Recall = \frac{TP}{TP + FN} \quad (4)$$

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (5)$$

Các chỉ số này được tính toán tại mỗi khung thời gian (thường là 10ms), cho phép phân tích sâu sắc khả năng phân tách tín hiệu trong các phân đoạn ngắn và các khoảng hội thoại chồng lấn.

4. METHODOLOGY

4.1. Process Flow




Figure 2: Workflow

Ảnh 2 mô tả luồng xử lý âm thanh của dự án. Để đưa ra kết quả mong đợi, âm thanh sẽ được đưa qua 4 module. Dưới đây nhóm sẽ giải thích cơ bản về cách xử lý âm thanh của dự án.

4.2. VAD và quá trình tiền xử lý

4.2.1. Module phát hiện hoạt động giọng nói (VAD)

Để đảm bảo độ sạch của dữ liệu thô và tối ưu hóa chi phí tính toán theo thời gian thực, hệ thống triển khai VAD dựa trên năng lượng tín hiệu. Tín hiệu âm thanh liên tục được chia thành các khung trượt dài 30ms với bước nhảy 15ms. Năng lượng của mỗi khung được tính bằng trung bình bình phương biên độ:

$$E = \frac{1}{N} \sum_{n=1}^N x[n]^2 \quad (6)$$

trong đó N là số mẫu trong một khung và $x[n]$ là biên độ tại mẫu thứ n . Một khung được gán nhãn “có tiếng người” nếu E vượt ngưỡng 1% so với mức năng lượng cực đại của toàn bộ tín hiệu (threshold = 0.01). Để phản ánh đúng nhịp ngắt nghỉ tự nhiên và tránh phân mảnh câu thoại, thuật toán tích hợp cơ chế làm mượt bằng cách dung hợp các khoảng lặng ngắn dưới 0.3 giây nằm giữa các đoạn âm thanh. Đồng thời, kỹ thuật mở rộng biên (padding) được áp dụng với đệm 0.15 giây ở hai đầu mỗi phân đoạn VAD nhằm bảo toàn các âm vị ở ranh giới.

4.2.2. Module tối ưu hóa phân đoạn (Cut & Merge)

Sau VAD, các phân đoạn thô được tinh chỉnh để đáp ứng giới hạn 30 giây của Whisper, đồng thời duy trì tính toàn vẹn ngữ cảnh. Hai cơ chế song song được sử dụng: **Dung hợp (Merge Logic)**: Các đoạn thoại quá ngắn (dưới 3 giây) hoặc có khoảng cách liên kề quá hẹp (dưới 1 giây) sẽ được nối lại nếu tổng thời lượng sau gộp không vượt 30 giây, giúp tăng ngữ cảnh cho giải mã. **Phân tách gối đầu (Overlapping Cut)**: Với các đoạn liên tục dài hơn 30 giây, hệ thống áp dụng cửa sổ trượt gối đầu 2 giây. Ví dụ, đoạn 50 giây được cắt thành $[0, 30]$ và $[28, 50]$. Vùng gối đầu đóng vai trò “vùng đệm” để bảo toàn từ vựng nếu ranh giới cắt rơi giữa từ.

4.3. TS-RoPE

Trong Transformer xử lý chuỗi thời gian, self-attention tiêu chuẩn không tự nhận thức thứ tự thời gian giữa các khung. Hệ thống tích hợp Time-Synchronous Rotary Positional Encoding (TS-RoPE) để ánh xạ trực tiếp thông tin thời gian vào không gian biểu diễn của khối Attention. Self-attention tiêu chuẩn được định nghĩa:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (7)$$

TS-RoPE xoay các vector truy vấn Q và khóa K theo góc tỷ lệ với vị trí thời gian t . Ma trận quay tại vị trí t cho từng cặp chiều được biểu diễn:

$$R_{\theta,t} = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix} \quad (8)$$

Khi áp dụng lên q_t và $k_{t'}$:

$$q'_t = R_{\theta,t}q_t, \quad k'_{t'} = R_{\theta,t'}k_{t'} \quad (9)$$

Khi đó tích vô hướng trở thành:

$$\langle q'_t, k'_{t'} \rangle = q_t^T R_{\theta,t}^T R_{\theta,t'} k_{t'} = q_t^T R_{\theta,t'-t} k_{t'} \quad (10)$$

Hệ quả là điểm số Attention phụ thuộc trực tiếp vào khoảng cách thời gian tương đối ($t' - t$) thay vì vị trí tuyệt đối.

4.4. Hyper-SD

4.4.1. Mô hình trích xuất đặc trưng người nói

Để thuật toán phân cụm có thể định danh chính xác luồng thoại của từng cá nhân, hệ thống đề xuất sử dụng module Hyper-SD nhằm chuyển đổi tín hiệu âm thanh thành các biểu diễn vector (embeddings) có tính phân biệt cao. Mục tiêu cốt lõi của Hyper-SD là kiến tạo một không gian nhúng tối ưu, nơi đảm bảo độ co cụm nội lớp (các khung âm thanh của cùng một người nói nằm sát nhau) và độ phân tách liên lớp (các khung của những người nói khác nhau bị đẩy ra xa).

Bên cạnh đó, module này còn đóng vai trò chuẩn hóa thông tin âm học, loại bỏ các yếu tố nhiễu loạn sinh ra do sự biến thiên về biên độ âm lượng, cao độ giọng nói (pitch), hay sự khác biệt về đặc tuyến của thiết bị thu âm.

Về mặt quy trình thuật toán, luồng hoạt động của Hyper-SD được thiết kế chặt chẽ qua các bước chuyển đổi tuần tự. Đầu tiên, phân đoạn âm thanh đã được làm sạch qua module VAD được chia nhỏ thành các khung (frames) với độ dài chuẩn 25

textms. Ví dụ, một đoạn thoại 60 giây sẽ được giải mã thành một chuỗi gồm 2400 khung. Từ tín hiệu của từng khung, hệ thống tiến hành trích xuất các đặc trưng âm học tầng thấp, tiêu biểu là biểu diễn phổ log-Mel hoặc MFCC. Những đặc trưng thô này sau đó được truyền tiếp qua một kiến trúc mạng nơ-ron sâu (bao gồm các khối biểu diễn như CNN, LSTM hoặc Transformer) để ánh xạ thành các vector đặc trưng không gian 512 chiều.

Điểm đột phá của Hyper-SD nằm ở khâu tối ưu hóa vector đầu ra. Hệ thống áp dụng hàm mất mát theo cơ chế học đối chiếu (Contrastive Learning) kết hợp với kỹ thuật

chuẩn hóa L_2 ($L_2\text{text-normalization}$). Phép chuẩn hóa này ép tất cả các vector nhúng về cùng một thang đo chiều dài đơn vị. Nhờ đó, ngay cả khi hai khung âm thanh của cùng một người có mức năng lượng khác biệt (một câu nói to và một câu nói nhỏ), biểu diễn vector của chúng vẫn hội tụ về một điểm. Ngược lại, những vector mang đặc trưng sinh trắc học khác biệt (chẳng hạn như tần số cơ bản giữa giọng nam và giọng nữ) sẽ được định vị ở các phân khu tách biệt hoàn toàn trong không gian 512 chiều. Quy trình vận hành được thực hiện theo một chuỗi xử lý thống nhất: đầu vào trước hết được đồng bộ về tần số lấy mẫu 16kHz, sau đó áp dụng VAD dựa trên năng lượng để loại bỏ im lặng/nhiều dưới ngưỡng và cắt gộp các đoạn quá dài (trên 30 giây) hoặc quá ngắn (dưới 0.5 giây) nhằm tạo dữ liệu ổn định; tiếp theo, tín hiệu được tách bằng cửa sổ trượt 1.5 giây, chuyển sang biểu diễn Mel-spectrogram và đưa qua WavLM để trích xuất vector đặc trưng 512 chiều phục vụ phân cụm phổ xác định nhóm người nói cùng ranh giới thời gian; sau đó hệ thống thực hiện đối chiếu có trọng số giữa kết quả phân cụm WavLM và suy diễn MASR, chỉ chốt quyết định khi đạt mức đồng thuận cao để tăng độ tin cậy; cuối cùng, các phân đoạn đã làm sạch và định danh được giải mã bằng PhoWhisper-Large cho tiếng Việt, hậu xử lý hợp nhất các đoạn liên tiếp cùng người nói và xuất kết quả ở các định dạng TXT, SRT hoặc JSON kèm mốc thời gian.

5. RESULTS AND VISUALIZATION

5.1. Hiệu năng tổng thể

Hệ thống MASR được đánh giá trên tập validation của ViMD.fix gồm 1494 mẫu âm thanh với ba chỉ số: WER, CER và DER. Kết quả đạt WER tổng thể 42.6% và DER 18.0%, cho thấy mô-đun WavLM kết hợp Spectral Clustering hoạt động ổn định trong tác vụ phân đoạn và gán nhãn người nói.




Figure 3: Kết quả WER và DER trên tập validation ViMD.fix

5.2. Đánh giá trên chồng chéo âm thanh

Để đánh giá độ mạnh mẽ (robustness) của hệ thống, chúng tôi tiến hành phân tích chi tiết hiệu năng trên hai nhánh dữ liệu: hội thoại thông thường (chỉ một người nói tại một thời điểm) và hội thoại có sự chồng chéo âm thanh.

Kết quả cho thấy sự chênh lệch rõ rệt về hiệu năng nhận dạng. Đối với nhóm dữ liệu không có hiện tượng chồng chéo (726 mẫu), hệ thống đạt độ chính xác khá cao

với WER giảm xuống chỉ còn 21.36%. Ngược lại, trên tập dữ liệu chứa các đoạn hội thoại chồng chéo (768 mẫu), chỉ số WER tăng mạnh lên mức 52.19%. Sự suy giảm hiệu năng này là một thách thức điển hình trong các hệ thống ASR hiện tại, khi sự giao thoa tín hiệu làm giảm chất lượng trích xuất đặc trưng âm học trước khi đưa vào mô hình PhoWhisper-Large.

5.3. Đồng thuận MASR và WavLM




Figure 4: Kết quả đồng thuận giữa MASR và WavLM trong pipeline đề xuất

Cơ chế kiểm chứng chéo (Cross-Reference) tích hợp trong pipeline cho thấy hiệu quả trong việc củng cố các dự đoán phân mảnh. Trong tổng số các phân đoạn được xử lý, có 3080 phân đoạn ghi nhận sự đồng thuận cao (Agreement) giữa mô hình MASR và quyết định gom cụm của WavLM. Có 2294 phân đoạn được quyết định chỉ dựa trên WavLM, cho thấy hệ thống có khả năng tự động điều chỉnh và sao lưu về mô hình cơ sở khi module MASR không đạt ngưỡng tin cậy.

Về mặt chi phí tính toán, pipeline đạt tốc độ xử lý trung bình là 7.0 giây cho mỗi mẫu âm thanh. Tốc độ này chứng minh tính khả thi của việc triển khai kết hợp các mô hình lớn (PhoWhisper-Large) cùng kiến trúc Diarization đa tầng trong các ứng dụng thực tế mà không đòi hỏi tài nguyên tính toán quá khắt khe.

6. LIMITATIONS AND FUTURE WORK

6.1. Limitations

Nghiên cứu vẫn còn một số hạn chế. Hệ thống hiện còn phụ thuộc vào WavLM trong khâu kiểm chứng và gán nhãn người nói, do đó hiệu năng tổng thể vẫn bị ảnh hưởng bởi chất lượng của mô-đun này. Bên cạnh đó, độ chính xác khi đánh giá trên các tập dữ liệu mới vẫn chưa ổn định như kỳ vọng.

6.2. Future Work

Trong tương lai, nhóm định hướng phát triển một kiến trúc MASR độc lập hơn, giảm dần sự phụ thuộc vào WavLM trong pipeline. Đồng thời, nhóm sẽ tập trung cải thiện khả năng tổng quát hóa để tăng độ chính xác trên dữ liệu ngoài miền huấn luyện và các bối cảnh hội thoại phức tạp.

7. CONCLUSION

Nghiên cứu này đề xuất một pipeline MASR cho tiếng Việt bằng cách kết hợp TS-RoPE trong khối mã hóa, Hyper-SD cho diarization và cơ chế kiểm chứng chéo giữa MASR với WavLM. Trên tập validation ViMD.fix, hệ thống đạt WER tổng thể 42.6% và DER 18.0%, đồng thời duy trì thời gian xử lý trung bình 7.0 giây/mẫu. Kết quả cho thấy hướng tiếp cận tích hợp giúp cải thiện độ ổn định trong gắn nhãn người nói, đặc biệt trong các hội thoại nhiều lượt chuyển lời.

References

- [1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, “Robust speech recognition via large-scale weak supervision,” arXiv:2212.04356, 2022.
- [2] Y. Hu, P. Yang, Z. Wang, Y. Zhong, and R. Liu, “TellWhisper: Tell Whisper who speaks when,” arXiv:2601.03712v2, Jan. 2026.
- [3] T.-T. Le, L. T. Nguyen, and D. Q. Nguyen, “PhoWhisper: Automatic speech recognition for Vietnamese,” in Proc. ICLR 2024 Tiny Papers Track.
- [4] J. Carletta, et al., “The AMI Meeting Corpus: A Pre-Announcement,” in Machine Learning for Multimodal Interaction (LNAI), vol. 3869, pp. 28-39, 2006. doi: 10.1007/11677482₃.
- [4] “The AMI Corpus - OPENSRL,” 2023. [Online]. Available: <https://www.openslr.org/16/>
- [5] N. V. Dinh, et al., “Multi-Dialect Vietnamese: Task, Dataset, Baseline Models and Challenges,” arXiv:2410.03458 [cs.CL], EMNLP 2024.